# Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Andryansyah Amir
NIM 124400065
Teknik Telekomunikasi, ITERA
andryansyah.124400065@student.itera.ac.id

***Ringkasan*—Prakiraan trafik internet per jam pada tingkat sel membantu operator seluler merencanakan kapasitas jaringan. Studi ini membandingkan ANN, RNN, LSTM, dan GRU pada data Telecom Italia di kotak Duomo, Milan, dan menguji generalisasinya di Bandara Linate. Dengan studi ablasi, lima faktor wajib (panjang jendela, ukuran hidden, jumlah lapisan, *learning rate*, dan kelompok fitur) serta tiga faktor pilihan (*optimizer*, fungsi *loss*, dan *patience*) diubah satu per satu dari konfigurasi acuan, masing-masing dengan tiga seed. Pada acuan, RNN dan GRU mencapai test MAE $229{,}6 \pm 5{,}1$ dan $237{,}2 \pm 9{,}3$, jauh di bawah ANN ($309{,}9 \pm 5{,}9$) dan baseline naif terbaik ($467{,}6$). ANN paling sensitif terhadap panjang jendela (val MAE $211{,}5$ menjadi $298{,}2$ saat $W$ naik dari 6 ke 168 jam), sedangkan GRU paling diuntungkan oleh ukuran hidden besar (val MAE $188{,}7$ pada hidden 128 dibanding $207{,}5$ pada acuan). *Learning rate* $10^{-4}$ dan SGD gagal konvergen dalam 300 epoch. Hasil menunjukkan bahwa model rekuren lebih akurat dan lebih tahan terhadap pilihan hyperparameter daripada ANN pada data ini.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

## I. Pendahuluan

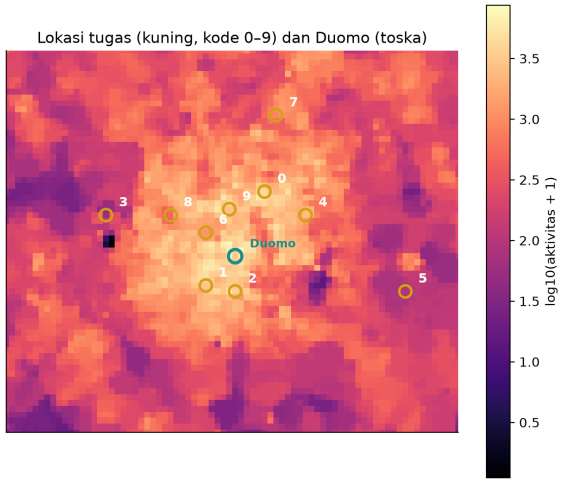
Prakiraan trafik per sel membantu operator seluler merencanakan kapasitas, menghemat energi pada jam sepi, dan mendeteksi lonjakan yang tidak biasa. Trafik per jam memiliki pola harian dan mingguan yang kuat, sehingga model sekuensial seperti RNN, LSTM [1], dan GRU [2] diharapkan lebih unggul daripada ANN yang memperlakukan jendela masukan sebagai vektor datar. Namun, membandingkan model pada satu konfigurasi saja dapat menyesatkan karena hasilnya bergantung pada pilihan hyperparameter. Studi ablasi mengubah satu faktor dalam satu waktu dari konfigurasi acuan, sehingga pengaruh tiap faktor dapat dipisahkan. Kontribusi laporan ini:

- ablasi delapan faktor (lima wajib, tiga pilihan) pada empat model dengan tiga seed;
- perbandingan konfigurasi terbaik dengan acuan dan baseline naif pada minggu test dan Natal;
- uji generalisasi konfigurasi terbaik di lokasi kelompok.

## II. Data dan Metode

### A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3], yang dipakai dalam versi agregat per jam dari [4], mencakup November–Desember 2013 dengan resolusi satu jam. Setiap kotak grid Milan memiliki tiga deret waktu: aktivitas internet (*net*, yang menjadi target prediksi), panggilan (*call*), dan SMS (*sms*). Dua fitur waktu ditambahkan, yaitu jam dan hari dalam seminggu, masing-masing dikodekan sebagai sinus dan kosinus, sehingga total tujuh fitur. Lokasi utama adalah kotak Duomo (5060). Lokasi kelompok adalah kode 5, Bandara Linate (kotak 4489); posisi lokasi tugas ditunjukkan pada Gambar 1.




Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

### B. Pembagian Data dan Praproses

Data dibagi berdasarkan waktu: latih 11 November–8 Desember (28 hari, 672 sampel), validasi 9–15 Desember, test 16–22 Desember, dan minggu Natal 23–29 Desember 2013. Minggu 4–10 November hanya menjadi konteks untuk jendela awal. Data deret waktu tidak boleh diacak karena sampel yang berdekatan saling berkorelasi; pengacakan membuat model melihat masa depan saat berlatih sehingga galat tampak lebih kecil daripada yang akan terjadi ketika model benar-benar meramal. Standarisasi memakai rata-rata dan simpangan baku dari data sebelum minggu validasi saja, agar tidak ada informasi validasi dan test yang bocor ke pelatihan. Pada *windowing*, setiap sampel berupa jendela $W$ jam terakhir sebagai masukan dan nilai *net* jam berikutnya sebagai target (horizon 1).

### C. Model dan Konfigurasi Acuan

ANN meratakan jendela masukan $[W, \text{fitur}]$ menjadi satu vektor, melewatkannya ke sejumlah lapisan tersembunyi dengan aktivasi ReLU, lalu satu lapisan keluaran. RNN, LSTM,

Tabel I
KONFIGURASI ACUAN

| Hyperparameter | Nilai acuan |
|---|---|
| Panjang jendela $W$ | 24 jam |
| Horizon | 1 jam |
| Ukuran hidden | ANN 32, RNN 68, LSTM 33, GRU 38 |
| Jumlah lapisan | ANN 2, rekuren 1 |
| Fitur | net, call, sms, jam, hari (7) |
| Optimizer, *learning rate* | Adam, $10^{-3}$ |
| *Batch size* | 64 |
| *Early stopping* | *patience* 30, maks. 300 epoch |

Tabel II
MAE BASELINE NAIF DAN KONFIGURASI ACUAN DI DUOMO (MODEL: RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

| Metode | Val | Test | Natal |
|---|---|---|---|
| Naif: terakhir | 662,6 | 600,9 | 431,2 |
| Naif: kemarin | 595,3 | 552,2 | 921,5 |
| Naif: minggu lalu | 492,8 | 467,6 | 1426,2 |
| ANN | $248{,}9 \pm 8{,}9$ | $309{,}9 \pm 5{,}9$ | $680{,}1 \pm 52{,}0$ |
| RNN | $206{,}1 \pm 7{,}4$ | $229{,}6 \pm 5{,}1$ | $421{,}2 \pm 2{,}4$ |
| LSTM | $230{,}5 \pm 12{,}2$ | $273{,}6 \pm 25{,}4$ | $586{,}0 \pm 56{,}8$ |
| GRU | $207{,}5 \pm 3{,}8$ | $237{,}2 \pm 9{,}3$ | $468{,}2 \pm 21{,}8$ |

dan GRU menumpuk lapisan rekuren dan mengambil *hidden state* pada jam terakhir, yang kemudian dipetakan ke keluaran dengan satu lapisan linear. LSTM dan GRU menambahkan gerbang pada sel rekuren untuk mengatur informasi yang disimpan dan dilupakan. Seluruh model diimplementasikan dengan PyTorch [5]. Ukuran hidden acuan dipilih agar jumlah parameter model rekuren sekitar 5,5 ribu (RNN 5.305, LSTM 5.578, GRU 5.397; ANN 6.497), sehingga perbandingan pada acuan relatif adil dalam kapasitas (Tabel I).

### D. Protokol Ablasi dan Evaluasi

Satu faktor diubah setiap kali, faktor lain tetap pada acuan. Faktor wajib: A1 panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam, A2 ukuran hidden $\{16, 32, 64, 128\}$, A3 jumlah lapisan $\{1, 2, 3\}$, A4 *learning rate* $\{10^{-4}, 10^{-3}, 10^{-2}\}$, dan A5 kelompok fitur (net; net+call+sms; net+waktu; semua). Faktor pilihan: B3 *optimizer* (Adam, AdamW, SGD), B4 fungsi *loss* (MSE, MAE, Huber), dan B5 *patience* $\{10, 30, 60\}$. Setiap konfigurasi dilatih dengan tiga seed (0, 1, 2) dan dilaporkan sebagai rata-rata ± simpangan baku. Metrik adalah MAE, RMSE, dan MAPE pada skala asli (bukan skala terstandarisasi). *Early stopping* memakai MSE validasi dan memulihkan bobot terbaik. Konfigurasi terbaik dipilih berdasarkan val MAE, sedangkan minggu test dan Natal hanya dipakai untuk pelaporan. Seluruh pelatihan berjalan di CPU dengan PyTorch 2.14.1, dengan total waktu pelatihan 71,3 menit.

## III. HASIL

### A. Baseline Naif dan Acuan

Tabel II memuat tiga tebakan naif (nilai terakhir, jam yang sama kemarin, dan jam yang sama minggu lalu) serta hasil konfigurasi acuan. Pada minggu test, baseline naif terbaik adalah "minggu lalu" dengan MAE 467,6. Semua model acuan mengungguli angka ini: RNN (229,6) dan GRU (237,2) sekitar dua kali lebih baik, sedangkan LSTM (273,6) dan ANN (309,9) sekitar 1,5–1,7 kali lebih baik. Di antara model, RNN paling akurat dan ANN paling lemah; selisih RNN dan GRU lebih kecil daripada simpangan baku GRU (9,3), sehingga keduanya belum dapat dibedakan. Pada minggu Natal, urutan baseline berubah: tebakan "minggu lalu" memburuk drastis (1426,2) karena pola Natal berbeda dari minggu biasa, sedangkan "nilai terakhir" (431,2) menjadi baseline terbaik. Hanya RNN ($421{,}2 \pm 2{,}4$) yang berada di bawah angka tersebut; ANN, LSTM, dan GRU lebih buruk.

### B. Ablasi Wajib

**A1, panjang jendela.** Pada ANN, memperpanjang jendela memburuk secara monoton: val MAE naik dari 211,5 ($W = 6$) ke 298,2 ($W = 168$) dan test MAE dari 269,4 ke 402,0, sementara jumlah parameter membengkak dari 2.465 ke 38.753 dan epoch efektif turun dari 166,7 ke 76,3 (Gambar 2 dan Tabel IV). Model rekuren hampir tidak terpengaruh karena parameternya tetap 5.305 (RNN), 5.578 (LSTM), dan 5.397 (GRU). RNN terbaik pada $W = 48$ (200,1), GRU datar di 206,7–212,6, dan LSTM terbaik pada $W = 6$ (227,1) tanpa pola yang jelas.

**A2, ukuran hidden.** Model rekuren paling diuntungkan: val MAE GRU turun dari 216,8 ke 188,7, LSTM dari 244,3 ke 207,1, dan RNN dari 247,0 ke 207,2 (jenuh pada hidden 64). ANN membaik lebih lambat (257,6 → 233,8). Pada hidden 128, LSTM memiliki 70.273 parameter dan GRU 52.737, dibanding RNN 17.665, sehingga perbandingan antar model pada hidden yang sama tidak setara dalam parameter.

**A3, jumlah lapisan.** Menambah lapisan umumnya merugikan. LSTM paling terdampak (val MAE 230,5 → 254,8 → 338,9; test MAE 412,6 pada tiga lapisan), RNN memburuk pada tiga lapisan (225,1), dan epoch efektif menurun (RNN 163,7 → 96,0). GRU dua lapisan ($203{,}3 \pm 9{,}6$) sedikit lebih baik daripada satu lapisan ($207{,}5 \pm 3{,}8$), tetapi selisihnya di dalam simpangan baku.

**A4, *learning rate*.** Pada $10^{-4}$ semua model berhenti di batas 300 epoch sebelum konvergen (val MAE 285,0–399,4). Pada $10^{-2}$ pelatihan cepat (sekitar 62–68 epoch) dan LSTM terbaik (215,9), GRU setara dengan acuan (208,2), sedangkan RNN (227,2) dan ANN (261,8, simpangan baku 16,6) memburuk.

**A5, kelompok fitur.** Memakai *net* saja terburuk untuk semua model rekuren (RNN 245,2, LSTM 266,2, GRU 264,6). Fitur *call* dan *sms* membantu RNN (245,2 → 224,1), fitur waktu membantu GRU (264,6 → 213,2) dan LSTM (266,2 → 231,1), dan gabungan semua fitur terbaik atau setara untuk ketiganya. ANN hampir tidak mendapat manfaat dari *call* dan *sms* (260,5 → 259,9) dan sedikit terbantu fitur waktu (246,0).

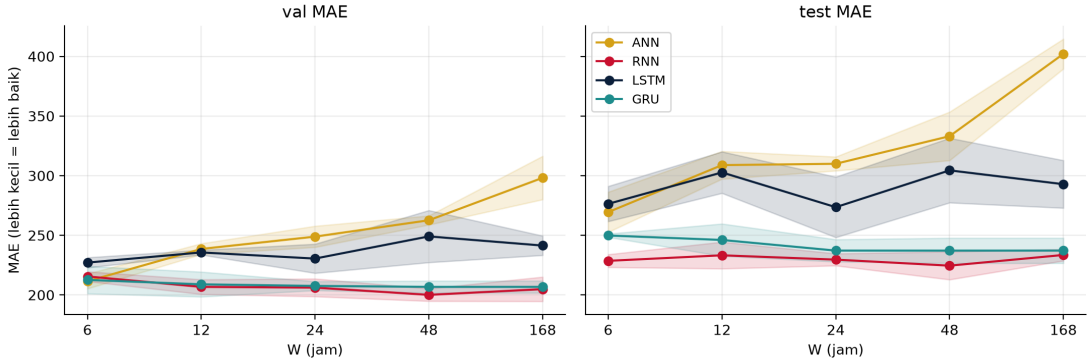
### C. Ablasi Pilihan

Dari tujuh faktor pilihan, kelompok memilih B4 (fungsi *loss*) dan B3 (*optimizer*); hasil B5 (*patience*) dirangkum di akhir. Seluruh nilai val MAE ada di Tabel III.

Tabel III
ABLASI FAKTOR TUNGGAL DI DUOMO: VAL MAE (RATA-RATA ± SIMPANGAN BAKU, 3 SEED). CETAK TEBAL: NILAI TERBAIK TIAP MODEL DALAM SATU FAKTOR. FITUR: N+C+S = NET+CALL+SMS; N+WAKTU = NET+JAM+HARI.

| Faktor / nilai | ANN | RNN | LSTM | GRU |
|---|---|---|---|---|
| *A1: panjang jendela $W$ (jam)* | | | | |
| 6 | **211,5** ± 6,2 | 215,5 ± 4,1 | **227,1** ± 4,3 | 212,6 ± 11,5 |
| 12 | 238,5 ± 4,5 | 206,7 ± 6,2 | 235,6 ± 2,0 | 208,9 ± 10,4 |
| 24 | 248,9 ± 8,9 | 206,1 ± 7,4 | 230,5 ± 12,2 | 207,5 ± 3,8 |
| 48 | 262,6 ± 3,8 | **200,1** ± 5,3 | 249,1 ± 21,8 | **206,7** ± 5,0 |
| 168 | 298,2 ± 18,2 | 204,8 ± 10,2 | 241,4 ± 8,1 | **206,7** ± 5,1 |
| *A2: ukuran hidden* | | | | |
| 16 | 257,6 ± 28,0 | 247,0 ± 5,8 | 244,3 ± 18,3 | 216,8 ± 21,2 |
| 32 | 248,9 ± 8,9 | 218,7 ± 6,6 | 241,5 ± 20,5 | 210,2 ± 0,8 |
| 64 | 238,4 ± 16,5 | **207,2** ± 12,8 | 218,1 ± 1,9 | 198,4 ± 9,2 |
| 128 | **233,8** ± 1,9 | 207,7 ± 7,2 | **207,1** ± 8,4 | **188,7** ± 4,2 |
| *A3: jumlah lapisan* | | | | |
| 1 | **240,9** ± 7,5 | **206,1** ± 7,4 | **230,5** ± 12,2 | 207,5 ± 3,8 |
| 2 | 248,9 ± 8,9 | 207,3 ± 9,1 | 254,8 ± 14,5 | **203,3** ± 9,6 |
| 3 | 249,3 ± 11,7 | 225,1 ± 12,7 | 338,9 ± 16,9 | 212,2 ± 15,9 |
| *A4: learning rate* | | | | |
| $10^{-4}$ | 295,4 ± 4,7 | 285,0 ± 13,7 | 399,4 ± 25,0 | 398,4 ± 8,6 |
| $10^{-3}$ | **248,9** ± 8,9 | **206,1** ± 7,4 | 230,5 ± 12,2 | **207,5** ± 3,8 |
| $10^{-2}$ | 261,8 ± 16,6 | 227,2 ± 6,4 | **215,9** ± 14,2 | 208,2 ± 5,6 |

| Faktor / nilai | ANN | RNN | LSTM | GRU |
|---|---|---|---|---|
| *A5: kelompok fitur* | | | | |
| net | 260,5 ± 7,0 | 245,2 ± 5,8 | 266,2 ± 5,7 | 264,6 ± 7,0 |
| n+c+s | 259,9 ± 5,2 | 224,1 ± 2,3 | 243,7 ± 7,1 | 231,8 ± 12,6 |
| n+waktu | **246,0** ± 9,8 | 223,0 ± 9,5 | 231,1 ± 4,3 | 213,2 ± 18,2 |
| semua | 248,9 ± 8,9 | **206,1** ± 7,4 | **230,5** ± 12,2 | **207,5** ± 3,8 |
| *B3: optimizer* | | | | |
| adam | 248,9 ± 8,9 | **206,1** ± 7,4 | **230,5** ± 12,2 | **207,5** ± 3,8 |
| adamw | **246,3** ± 11,9 | **206,1** ± 7,4 | **230,5** ± 12,2 | **207,5** ± 3,8 |
| sgd | 279,2 ± 12,4 | 299,2 ± 10,2 | 413,6 ± 14,3 | 371,2 ± 2,0 |
| *B4: fungsi loss* | | | | |
| mse | 248,9 ± 8,9 | **206,1** ± 7,4 | **230,5** ± 12,2 | **207,5** ± 3,8 |
| mae | **238,4** ± 5,3 | 217,9 ± 9,3 | 239,2 ± 9,6 | 213,5 ± 14,7 |
| huber | 241,9 ± 3,7 | 206,3 ± 10,0 | 233,6 ± 13,6 | 207,8 ± 5,1 |
| *B5: patience* | | | | |
| 10 | 271,8 ± 23,2 | 220,2 ± 11,4 | 250,1 ± 2,5 | 218,1 ± 4,8 |
| 30 | 248,9 ± 8,9 | **206,1** ± 7,4 | 230,5 ± 12,2 | 207,5 ± 3,8 |
| 60 | **241,8** ± 3,8 | 206,6 ± 7,0 | **223,3** ± 7,6 | **205,6** ± 9,9 |




Gambar 2. Pengaruh panjang jendela $W$ terhadap MAE validasi (kiri) dan test (kanan) di Duomo. Garis: rata-rata tiga seed; area: ±1 simpangan baku.

Tabel IV
PENGARUH PANJANG JENDELA $W$ TERHADAP TEST MAE DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED). CETAK TEBAL: TEST MAE TERENDAH TIAP MODEL; PEMILIHAN KONFIGURASI TETAP MEMAKAI VAL MAE (TABEL III).

| $W$ (jam) | ANN | RNN | LSTM | GRU |
|---|---|---|---|---|
| 6 | **269,4 ± 16,8** | 228,6 ± 5,4 | 276,3 ± 14,7 | 249,8 ± 1,4 |
| 12 | 308,8 ± 11,6 | 233,2 ± 11,2 | 302,7 ± 17,4 | 246,1 ± 13,5 |
| 24 | 309,9 ± 5,9 | 229,6 ± 5,1 | **273,6 ± 25,4** | 237,2 ± 9,3 |
| 48 | 333,1 ± 20,3 | **224,5 ± 11,7** | 304,4 ± 27,1 | **237,1 ± 10,6** |
| 168 | 402,0 ± 12,5 | 233,5 ± 4,8 | 292,8 ± 20,0 | 237,2 ± 10,6 |

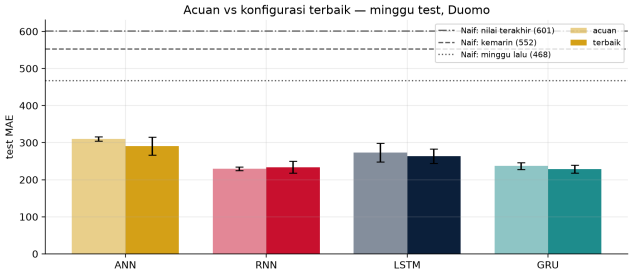
**B4, fungsi *loss*.** Pada validasi, *loss* MAE hanya menguntungkan ANN (val MAE 238,4 vs 248,9 untuk MSE) dan justru merugikan RNN (217,9 vs 206,1), LSTM (239,2 vs 230,5), dan GRU (213,5 vs 207,5), sedangkan Huber setara dengan MSE. Pada minggu test hasilnya berbalik: test MAE dengan *loss* MAE lebih rendah untuk RNN (229,6 → 207,1), GRU (237,2 → 220,6), ANN (309,9 → 299,3), dan LSTM (273,6 → 270,1). Karena konfigurasi dipilih dengan val MAE, *loss* MSE dipertahankan untuk model rekuren dan MAE hanya dipakai pada ANN.

**B3, *optimizer*.** SGD pada *learning rate* $10^{-3}$ tidak konvergen dalam 300 epoch pada semua model (val MAE 279,2–413,6, jauh di atas Adam). AdamW menghasilkan angka identik dengan Adam untuk RNN, LSTM, dan GRU, dan hanya selisih kecil pada ANN (246,3 ± 11,9 vs 248,9 ± 8,9, di dalam simpangan baku). Peluruhan bobot AdamW yang kecil kemungkinan menjadi penyebabnya. Dugaan bahwa SGD memerlukan *learning rate* yang berbeda tidak diuji lebih lanjut.

**B5, *patience*.** *Patience* 10 memburuk di semua model (misalnya ANN 271,8, RNN 220,2), sedangkan *patience* 60 hanya menguntungkan ANN (241,8) dan LSTM (223,3); RNN dan GRU sudah cukup dengan *patience* 30.

Tabel V
MAE ACUAN VS KONFIGURASI TERBAIK DI DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED). TERBAIK: ANN $W = 6$; RNN $W = 48$; LSTM DAN GRU HIDDEN 128.

| Model | Konfigurasi | Val | Test | Natal |
|---|---|---|---|---|
| ANN | acuan | $248{,}9 \pm 8{,}9$ | $309{,}9 \pm 5{,}9$ | $680{,}1 \pm 52{,}0$ |
| | terbaik | $211{,}5 \pm 6{,}2$ | $269{,}4 \pm 16{,}8$ | $532{,}5 \pm 78{,}1$ |
| RNN | acuan | $206{,}1 \pm 7{,}4$ | $229{,}6 \pm 5{,}1$ | $421{,}2 \pm 2{,}4$ |
| | terbaik | $200{,}1 \pm 5{,}3$ | $224{,}5 \pm 11{,}7$ | $404{,}5 \pm 9{,}9$ |
| LSTM | acuan | $230{,}5 \pm 12{,}2$ | $273{,}6 \pm 25{,}4$ | $586{,}0 \pm 56{,}8$ |
| | terbaik | $207{,}1 \pm 8{,}4$ | $245{,}6 \pm 6{,}7$ | $491{,}1 \pm 7{,}6$ |
| GRU | acuan | $207{,}5 \pm 3{,}8$ | $237{,}2 \pm 9{,}3$ | $468{,}2 \pm 21{,}8$ |
| | terbaik | $188{,}7 \pm 4{,}2$ | $220{,}3 \pm 10{,}6$ | $435{,}2 \pm 7{,}5$ |




Gambar 3. Test MAE acuan dan konfigurasi terbaik di Duomo, dengan garis baseline naif.

### D. Konfigurasi Terbaik

Untuk tiap model dipilih faktor yang memberi penurunan val MAE terbesar pada Tabel III: panjang jendela $W = 6$ untuk ANN, $W = 48$ untuk RNN, dan ukuran hidden 128 untuk LSTM dan GRU. Faktor lain dibiarkan pada acuan karena menggabungkan beberapa faktor sekaligus belum tentu menguntungkan. Tabel V dan Gambar 3 membandingkan konfigurasi ini dengan acuan dan baseline naif.

Pada minggu test, test MAE terbaik adalah ANN $269{,}4 \pm 16{,}8$ (turun $13{,}1\,\%$ dari acuan), RNN $224{,}5 \pm 11{,}7$ ($2{,}2\,\%$), LSTM $245{,}6 \pm 6{,}7$ ($10{,}2\,\%$), dan GRU $220{,}3 \pm 10{,}6$ ($7{,}1\,\%$). Penurunan pada ANN lebih besar daripada simpangan baku antar seed, sedangkan pada RNN jauh di bawahnya, sehingga RNN pada dasarnya tidak berubah. Semua model berada sekitar 1,7–2,1 kali lebih baik daripada baseline naif terbaik pada test (467,6).

Pada minggu Natal, MAE turun untuk semua model: ANN $680{,}1 \rightarrow 532{,}5$, RNN $421{,}2 \rightarrow 404{,}5$, LSTM $586{,}0 \rightarrow 491{,}1$, dan GRU $468{,}2 \rightarrow 435{,}2$. Hanya RNN yang berada di bawah baseline "nilai terakhir" (431,2); GRU setara dengannya, sedangkan ANN dan LSTM masih lebih buruk.

### E. Uji Generalisasi

Tabel VI memuat baseline naif, hasil acuan, dan hasil konfigurasi terbaik Duomo di Bandara Linate (kode 5). Skala trafik Linate jauh lebih kecil (MAE sekitar 8 dibanding sekitar 230 di Duomo), sehingga galat relatif lebih layak dibandingkan: test MAPE acuan di Linate 8,4–10,3 % dan di Duomo 8,0–11,3 %, sebanding.

**Urutan model.** Pada acuan, RNN dan GRU terbaik (test MAE 7,5), disusul LSTM (8,2) dan ANN (8,8). Urutan ini sama dengan di Duomo (RNN, GRU, LSTM, ANN), tetapi jarak antar model menyempit: ANN lebih buruk daripada RNN sebesar $35\,\%$ di Duomo dan hanya $17\,\%$ di Linate. Setelah konfigurasi terbaik dipakai, RNN (7,6) dan GRU (7,9) tetap menjadi dua model terbaik, sedangkan ANN dan LSTM setara (8,3 keduanya), sehingga urutan acuan (RNN, GRU, LSTM, ANN) hanya berubah pada dua posisi terbawah. Selisih antar model ini sebanding dengan simpangan baku antar seed (0,3–0,6), jadi urutan tersebut tidak dapat dinyatakan berubah secara meyakinkan.

**Apakah konfigurasi terbaik Duomo tetap unggul?** Konfigurasi terbaik Duomo tidak memberi perbaikan yang berarti di Linate. Dengan aturan bahwa selisih di dalam simpangan baku berarti tidak berbeda nyata, ANN ($8{,}8 \pm 0{,}7 \rightarrow 8{,}3 \pm 0{,}6$), RNN ($7{,}5 \pm 0{,}1 \rightarrow 7{,}6 \pm 0{,}3$), dan LSTM ($8{,}2 \pm 0{,}2 \rightarrow 8{,}3 \pm 0{,}3$) tidak berubah secara nyata. Hanya GRU yang sedikit memburuk ($7{,}5 \pm 0{,}2 \rightarrow 7{,}9 \pm 0{,}3$), karena selisihnya (0,4) melebihi simpangan baku kedua konfigurasi. Jadi pengaturan yang menguntungkan di Duomo tidak otomatis berpindah ke lokasi lain.

**Baseline naif dan minggu Natal.** Semua model mengalahkan baseline naif terbaik pada minggu test (10,1 untuk "nilai terakhir"). Pada minggu Natal, "nilai terakhir" (7,1) justru lebih baik daripada semua model, baik pada acuan (10,8–14,4) maupun pada konfigurasi terbaik. Pola ini juga terlihat di Duomo, tempat hanya RNN yang mengalahkan baseline tersebut. Model dilatih pada minggu-minggu biasa, sehingga kemungkinan belum mempelajari pola minggu libur; dugaan ini belum diuji pada studi ini.

**Pola trafik lokasi.** Gambar **??** menunjukkan bahwa Duomo memiliki siklus harian yang sangat teratur, dengan puncak sekitar 6.000–9.000 dan lembah sekitar 1.000. Linate jauh lebih kecil (puncak sekitar 100–150) dan berfluktuasi lebih tajam dari jam ke jam, sehingga siklus hariannya kurang bersih. Di Linate juga tampak satu lonjakan tunggal (sekitar 230) pada sekitar 16 Desember, yang jatuh pada minggu test. Pada minggu Natal, trafik Duomo turun tajam sekitar 25–27 Desember (puncak harian turun dari sekitar 8.000 menjadi 1.600–3.400) lalu pulih pada 28–29 Desember, sedangkan trafik Linate menurun lebih landai dan bergerak pada kisaran sempit sekitar 30–100. Perubahan level yang mendadak ini sejalan dengan hasil di atas: di Duomo hanya RNN yang mengalahkan baseline "nilai terakhir", dan di Linate baseline itu mengalahkan semua model. Tebakan dari jam sebelumnya langsung mengikuti level baru, sedangkan model yang dilatih pada minggu biasa mengandalkan pola harian yang berubah pada minggu libur. Penjelasan ini masih berupa dugaan dan belum diuji.

## IV. PEMBAHASAN

**Mengapa ANN sensitif terhadap $W$.** Lapisan pertama ANN memiliki $W \times 7$ masukan, sehingga parameternya naik linear terhadap $W$ (2.465 pada $W = 6$ menjadi 38.753 pada $W = 168$), sementara hanya ada 672 sampel latih. Model

Tabel VI
MAE DI BANDARA LINATE (KODE 5): BASELINE NAIF, ACUAN, DAN KONFIGURASI TERBAIK DUOMO (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

| Model | Konfigurasi | Val | Test | Natal |
|---|---|---|---|---|
| Naif: terakhir | – | 10,4 | 10,1 | 7,1 |
| Naif: kemarin | – | 16,7 | 20,4 | 15,2 |
| Naif: minggu lalu | – | 13,0 | 15,4 | 28,5 |
| ANN | acuan | $8{,}7 \pm 0{,}0$ | $8{,}8 \pm 0{,}7$ | $14{,}4 \pm 0{,}5$ |
| | terbaik | $8{,}8 \pm 0{,}2$ | $8{,}3 \pm 0{,}6$ | $12{,}8 \pm 1{,}3$ |
| RNN | acuan | $8{,}5 \pm 0{,}1$ | $7{,}5 \pm 0{,}1$ | $10{,}8 \pm 0{,}1$ |
| | terbaik | $8{,}6 \pm 0{,}2$ | $7{,}6 \pm 0{,}3$ | $10{,}8 \pm 0{,}8$ |
| LSTM | acuan | $9{,}3 \pm 0{,}1$ | $8{,}2 \pm 0{,}2$ | $12{,}8 \pm 0{,}8$ |
| | terbaik | $9{,}0 \pm 0{,}3$ | $8{,}3 \pm 0{,}3$ | $12{,}7 \pm 0{,}5$ |
| GRU | acuan | $9{,}2 \pm 0{,}1$ | $7{,}5 \pm 0{,}2$ | $11{,}4 \pm 0{,}9$ |
| | terbaik | $9{,}1 \pm 0{,}3$ | $7{,}9 \pm 0{,}3$ | $11{,}3 \pm 0{,}5$ |

dengan parameter berlebih cepat menghafal data latih, sejalan dengan epoch efektif yang turun ($166{,}7 \rightarrow 76{,}3$) dan val MAE yang naik ($211{,}5 \rightarrow 298{,}2$). Model rekuren berbagi bobot sepanjang waktu, sehingga parameternya tidak bergantung pada $W$ dan hampir tidak terpengaruh. Ini penjelasan yang konsisten dengan data, tetapi tidak diuji langsung (misalnya dengan mengatur jumlah parameter ANN tetap).

**Kapasitas dan kedalaman.** Ukuran hidden yang lebih besar menguntungkan GRU dan LSTM, tetapi sebagian manfaat ini mungkin berasal dari bertambahnya parameter, bukan dari arsitektur gerbangnya: pada hidden yang sama LSTM memiliki sekitar empat kali dan GRU sekitar tiga kali parameter RNN. Pada acuan, ketika parameter kira-kira setara (sekitar 5,5 ribu), RNN ($229{,}6$) sebaik GRU ($237{,}2$) dan lebih baik daripada LSTM ($273{,}6$). Menumpuk lapisan merugikan, terutama pada LSTM (val MAE $230{,}5 \rightarrow 338{,}9$ pada tiga lapisan) dengan epoch efektif yang menurun; dugaan kami adalah optimisasi yang lebih sulit dan *overfitting* yang lebih cepat pada data sekecil ini, tetapi hal ini belum diuji.

**Faktor yang paling dan paling tidak berpengaruh.** Yang paling berpengaruh adalah faktor yang membuat pelatihan gagal atau kehilangan informasi: *learning rate* $10^{-4}$ (tidak konvergen dalam 300 epoch), SGD pada $10^{-3}$, dan penggunaan *net* saja tanpa *call*, *sms*, dan fitur waktu. Pada ANN, panjang jendela juga sangat berpengaruh. Yang relatif tidak berpengaruh adalah Adam vs AdamW, dan *patience* di atas 30 untuk RNN dan GRU. Pelajaran praktisnya, memilih nilai yang membuat pelatihan konvergen lebih menentukan daripada penyetelan halus.

**Perbedaan antar model vs antar seed.** Selisih ANN terhadap RNN pada acuan (test MAE sekitar $80$) jauh melebihi simpangan baku antar seed (maksimum $25{,}4$), sehingga keunggulan model rekuren atas ANN nyata. Selisih RNN dan GRU ($7{,}6$) lebih kecil daripada simpangan baku GRU ($9{,}3$), sehingga keduanya tidak dapat dibedakan. LSTM memiliki simpangan baku terbesar ($25{,}4$), tanda pelatihan yang kurang stabil. Perbaikan konfigurasi terbaik terhadap acuan melebihi simpangan baku seed pada ANN ($-40{,}5$ vs $16{,}8$), dan hanya sedikit melebihinya pada LSTM ($-28{,}0$ vs $25{,}4$) dan GRU ($-16{,}9$ vs $10{,}6$); pada RNN ($-5{,}1$ vs $11{,}7$) perubahannya di dalam simpangan baku sehingga tidak dapat dibedakan dari variasi antar seed.

**Pemilihan dengan validasi.** Kasus B4 memperlihatkan bahayanya memilih konfigurasi dengan data test: *loss* MAE tampak lebih baik pada test tetapi lebih buruk pada validasi untuk model rekuren. Dengan satu minggu validasi dan satu minggu test, perbedaan semacam itu juga bisa berasal dari kebetulan pada minggu tertentu.

**Minggu Natal.** Seluruh model dilatih pada minggu biasa sehingga tidak pernah melihat pola hari libur, sedangkan baseline "nilai terakhir" langsung mengikuti level terbaru. Hal ini sejalan dengan penurunan trafik Duomo pada akhir Desember (Gambar **??**) dan dengan hasil di Linate, tetapi sebabnya belum diuji.

**Keterbatasan.** Studi ini memakai satu kota, hanya empat minggu data latih (672 sampel), dan satu kali pembagian waktu, sehingga hasil bisa berbeda pada periode atau kota lain. Tiga seed hanya memberi estimasi simpangan baku yang kasar. Minggu test Linate memuat satu lonjakan tunggal (Gambar **??**) yang dapat memengaruhi test MAE semua model. Ablasi mengubah satu faktor setiap kali sehingga interaksi antar faktor tidak dieksplorasi, dan konfigurasi terbaik disusun dari faktor tunggal.

## V. KESIMPULAN

Model rekuren lebih akurat daripada ANN pada prediksi trafik per jam: pada acuan, test MAE RNN $229{,}6 \pm 5{,}1$ dan GRU $237{,}2 \pm 9{,}3$ berbanding $309{,}9 \pm 5{,}9$ untuk ANN, dan semua model sekitar 1,5–2 kali lebih baik daripada baseline naif terbaik ($467{,}6$), sementara RNN dan GRU tidak dapat dibedakan satu sama lain. ANN paling sensitif terhadap panjang jendela (val MAE $211{,}5 \rightarrow 298{,}2$ untuk $W = 6 \rightarrow 168$), GRU paling diuntungkan oleh hidden besar ($188{,}7$ pada hidden 128 vs $207{,}5$ pada acuan), sedangkan *learning rate* $10^{-4}$ dan SGD gagal konvergen dalam 300 epoch. Konfigurasi terbaik menghasilkan test MAE ANN $269{,}4 \pm 16{,}8$, RNN $224{,}5 \pm 11{,}7$, LSTM $245{,}6 \pm 6{,}7$, dan GRU $220{,}3 \pm 10{,}6$; perbaikan terhadap acuan jelas pada ANN ($-40{,}5$), marginal pada LSTM ($-28{,}0$) dan GRU ($-16{,}9$), dan tidak ada pada RNN ($-5{,}1$). Di Bandara Linate semua model acuan mengalahkan baseline naif pada minggu test (7,5–8,8 vs $10{,}1$), tetapi pada minggu Natal baseline "nilai terakhir" ($7{,}1$) lebih baik daripada semuanya ($10{,}8$–$14{,}4$); di Duomo hanya RNN yang mengunggulinya ($421{,}2$ vs $431{,}2$).

## KONTRIBUSI ANGGOTA

| | |
|---|---|
| Andryansyah Amir | Menjalankan semua dari bagian Data, Model, Konfigurasi Acuan, Training Pencatatan, dan A0 sampai Penutup, dengan menyesuaikan data berdasarkan ketentuan yang ada dan Membuat Laporan Latex |

## PERNYATAAN PENGGUNAAN AI

Saya menggunakan Claude (Anthropic). Claude digunakan untuk menjelaskan langkah pengerjaan tugas, serta membantu

menyusun draf teks laporan yang kemudian saya periksa dan sesuaikan. Seluruh angka dalam laporan berasal dari run yang kami jalankan sendiri dan tercatat di folder `hasil/` pada repositori.

## KODE DAN DATA

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/Andry132/dlw-tugas-ra-124400065.

## PUSTAKA


[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

[3] G. Barlacchi, M. De Nadai, R. Larcher, A. Casella, C. Chitic, G. Torrisi, F. Antonelli, A. Vespignani, A. Pentland, and B. Lepri, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *IEEE INFOCOM 2021 – IEEE Conference on Computer Communications*, 2021, pp. 1–10.

[5] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems 32 (NeurIPS)*, 2019, pp. 8024–8035.