Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Andryansyah Amir
NIM 124400065
Teknik Telekomunikasi, ITERA
andryansyah.124400065@student.itera.ac.id

Ade Raka Maulana
NIM 124400047
Teknik Telekomunikasi, ITERA
ade.124400047@student.itera.ac.id

***Ringkasan*—Prakiraan trafik internet per jam pada tingkat sel membantu operator seluler merencanakan kapasitas jaringan. Studi ini membandingkan ANN, RNN, LSTM, dan GRU pada data Telecom Italia di kotak Duomo, Milan, dan menguji generalisasinya di Bandara Linate. Dengan studi ablasi, lima faktor wajib (panjang jendela, ukuran hidden, jumlah lapisan, *learning rate*, dan kelompok fitur) serta tiga faktor pilihan (*optimizer*, fungsi *loss*, dan *patience*) diubah satu per satu dari konfigurasi acuan, masing-masing dengan tiga seed. Pada acuan, RNN dan GRU mencapai test MAE $229{,}6 \pm 5{,}1$ dan $237{,}2 \pm 9{,}3$, jauh di bawah ANN ($309{,}9 \pm 5{,}9$) dan baseline naif terbaik ($467{,}6$). ANN paling sensitif terhadap panjang jendela (val MAE $211{,}5$ menjadi $298{,}2$ saat W naik dari 6 ke 168 jam), sedangkan GRU paling diuntungkan oleh ukuran hidden besar (val MAE $188{,}7$ pada hidden 128 dibanding $207{,}5$ pada acuan). *Learning rate* 10^{-4} dan SGD gagal konvergen dalam 300 epoch. [Satu kalimat tentang konfigurasi terbaik dan hasil di Linate: isi setelah Bagian C dan D selesai.] Hasil menunjukkan bahwa model rekuren lebih akurat dan lebih tahan terhadap pilihan hyperparameter daripada ANN pada data ini.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

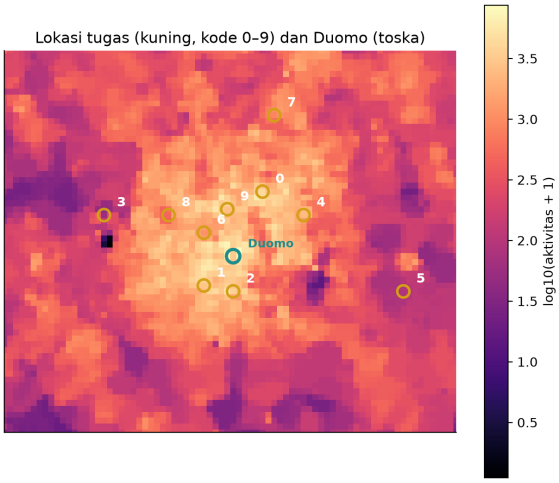
Prakiraan trafik per sel membantu operator seluler merencanakan kapasitas, menghemat energi pada jam sepi, dan mendeteksi lonjakan yang tidak biasa. Trafik per jam memiliki pola harian dan mingguan yang kuat, sehingga model sekuensial seperti RNN, LSTM [**?**], dan GRU [**?**] diharapkan lebih unggul daripada ANN yang memperlakukan jendela masukan sebagai vektor datar. Namun, membandingkan model pada satu konfigurasi saja dapat menyesatkan karena hasilnya bergantung pada pilihan hyperparameter. Studi ablasi mengubah satu faktor dalam satu waktu dari konfigurasi acuan, sehingga pengaruh tiap faktor dapat dipisahkan. Kontribusi laporan ini:

- ablasi delapan faktor (lima wajib, tiga pilihan) pada empat model dengan tiga seed;
- perbandingan konfigurasi terbaik dengan acuan dan baseline naif pada minggu test dan Natal;
- uji generalisasi konfigurasi terbaik di lokasi kelompok.

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [**?**], yang dipakai dalam versi agregat per jam dari [**?**], mencakup November–Desember 2013 dengan resolusi satu jam. Setiap kotak grid Milan memiliki tiga deret waktu: aktivitas internet (*net*, yang menjadi target prediksi), panggilan (*call*), dan SMS (*sms*). Dua fitur waktu ditambahkan, yaitu jam dan hari dalam seminggu, masing-masing dikodekan sebagai sinus dan kosinus, sehingga total tujuh fitur. Lokasi utama adalah kotak Duomo (5060). Lokasi kelompok adalah kode 5, Bandara Linate (kotak 4489); posisi lokasi tugas ditunjukkan pada Gambar 1.



Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

B. Pembagian Data dan Praproses

Data dibagi berdasarkan waktu: latih 11 November–8 Desember (28 hari, 672 sampel), validasi 9–15 Desember, test 16–22 Desember, dan minggu Natal 23–29 Desember 2013. Minggu 4–10 November hanya menjadi konteks untuk jendela awal. Data deret waktu tidak boleh diacak karena sampel yang berdekatan saling berkorelasi; pengacakan membuat model melihat masa depan saat berlatih sehingga galat tampak lebih kecil daripada yang akan terjadi ketika model benar-benar meramal. Standarisasi memakai rata-rata dan simpangan baku dari data sebelum minggu validasi saja, agar tidak ada informasi validasi dan test yang bocor ke pelatihan. Pada *windowing*, setiap sampel berupa jendela W jam terakhir sebagai masukan dan nilai *net* jam berikutnya sebagai target (horizon 1).

Tabel I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size	64
Early stopping	*patience* 30, maks. 300 epoch

C. Model dan Konfigurasi Acuan

ANN meratakan jendela masukan $[W, \text{fitur}]$ menjadi satu vektor, melewatkannya ke sejumlah lapisan tersembunyi dengan aktivasi ReLU, lalu satu lapisan keluaran. RNN, LSTM, dan GRU menumpuk lapisan rekuren dan mengambil *hidden state* pada jam terakhir, yang kemudian dipetakan ke keluaran dengan satu lapisan linear. LSTM dan GRU menambahkan gerbang pada sel rekuren untuk mengatur informasi yang disimpan dan dilupakan. Seluruh model diimplementasikan dengan PyTorch [**?**]. Ukuran hidden acuan dipilih agar jumlah parameter model rekuren sekitar 5,5 ribu (RNN 5.305, LSTM 5.578, GRU 5.397; ANN 6.497), sehingga perbandingan pada acuan relatif adil dalam kapasitas (Tabel I).

D. Protokol Ablasi dan Evaluasi

Satu faktor diubah setiap kali, faktor lain tetap pada acuan. Faktor wajib: A1 panjang jendela $W \in \{6, 12, 24, 48, 168\}$ jam, A2 ukuran hidden $\{16, 32, 64, 128\}$, A3 jumlah lapisan $\{1, 2, 3\}$, A4 *learning rate* $\{10^{-4}, 10^{-3}, 10^{-2}\}$, dan A5 kelompok fitur (net; net+call+sms; net+waktu; semua). Faktor pilihan: B3 *optimizer* (Adam, AdamW, SGD), B4 fungsi *loss* (MSE, MAE, Huber), dan B5 *patience* $\{10, 30, 60\}$. Hipotesis awal: [tulis hipotesis kelompokmu untuk B3, B4, B5 sebelum melihat hasil]. Setiap konfigurasi dilatih dengan tiga seed (0, 1, 2) dan dilaporkan sebagai rata-rata $\pm$ simpangan baku. Metrik adalah MAE, RMSE, dan MAPE pada skala asli (bukan skala terstandarisasi). *Early stopping* memakai MSE validasi dan memulihkan bobot terbaik. Konfigurasi terbaik dipilih berdasarkan val MAE, sedangkan minggu test dan Natal hanya dipakai untuk pelaporan. Seluruh pelatihan berjalan di CPU dengan PyTorch 2.14.1, dengan total waktu pelatihan 71,3 menit.

III. HASIL

A. Baseline Naif dan Acuan

[Tabel baseline naif dan hasil konfigurasi acuan (Bagian 0).]

B. Ablasi Wajib

[Satu subbagian atau paragraf per faktor A1–A5. Gunakan grafik dari folder `hasil/` (boleh digabung beberapa dalam satu gambar agar hemat tempat) dan tabel seperti Tabel II. Setiap gambar dan tabel harus dirujuk dan dibahas di teks.]

Tabel II
CONTOH FORMAT: PENGARUH PANJANG JENDELA W TERHADAP TEST MAE (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED). ANGKA DI BAWAH HANYA CONTOH.

W (jam)	ANN	RNN	LSTM	GRU
6	000 ± 00	000 ± 00	000 ± 00	000 ± 00
24	000 ± 00	$\mathbf{000 \pm 00}$	000 ± 00	000 ± 00
168	000 ± 00	000 ± 00	000 ± 00	000 ± 00

C. Ablasi Pilihan

[Dua faktor B pilihan kalian: hipotesis awal, hasil, dan apakah hipotesis terbukti.]

D. Konfigurasi Terbaik

[Konfigurasi terbaik tiap model (dipilih dengan val MAE), lalu hasilnya pada minggu test dan Natal dibandingkan dengan acuan dan baseline naif.]

E. Uji Generalisasi

[Hasil acuan vs terbaik di lokasi kelompok. Apakah urutan model berubah? Kaitkan dengan pola trafik lokasi tersebut.]

IV. PEMBAHASAN

[Bagian terpenting. Jangan hanya mengulang angka: jelaskan *mengapa*. Hyperparameter mana yang paling berpengaruh dan mana yang tidak? Apakah perbedaan antar model lebih besar daripada perbedaan antar seed? Apa keterbatasan studi ini (satu kota, 4 minggu train, satu kali pembagian waktu)?]

V. KESIMPULAN

[3–5 kalimat yang menjawab pertanyaan studi, dengan angka.]

KONTRIBUSI ANGGOTA

Nama Anggota 1	[contoh: Bagian A1–A3, penulisan Hasil]
Nama Anggota 2	[...]
Nama Anggota 3	[...]

PERNYATAAN PENGGUNAAN AI

[Tuliskan alat AI yang dipakai (misalnya ChatGPT, Claude, Copilot) dan untuk apa (memperbaiki kode, merapikan bahasa, dll.). Bila tidak memakai, tulis "Tidak ada." Seluruh angka harus berasal dari run kalian sendiri.]

KODE DAN DATA

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/username/nama-repo.

PUSTAKA